



机器人学中的状态估计

Timothy Barfoot 著 高翔, 谢晓佳等 译
Slides by Xiang Gao

2020年春



第3讲 非线性高斯系统的状态估计问题

- 引言
- 离散时间的递归估计
- 离散时间的批量估计
- 连续时间的批量估计



第3讲 非线性高斯系统的状态估计问题

- 引言
- 离散时间的递归估计
- 离散时间的批量估计
- 连续时间的批量估计




引言

- 上一讲我们介绍了LG系统状态估计问题，得到了几个主要结论
 - LG系统的MAP估计和贝叶斯推断给出了相同的结果
 - 递归形式可由批量形式导出，我们以Cholesky分解作为例子，给出了前向和后向迭代，组成RTS Smoother
 - 前向部分等价于卡尔曼滤波器，而卡尔曼滤波器亦可从MAP或贝叶斯滤波形式导出
- 本讲我们主要介绍NL系统下的状态估计，主要方法有：
 - 通用的贝叶斯滤波理论框架；
 - NL下的MAP
 - EKF、Sigma point 卡尔曼滤波（UKF）、粒子滤波

引言

- 我们知道LG系统中，贝叶斯推断的结果与MAP结果一致
 - 这主要是因为高斯分布经过线性变换之后仍然为高斯分布，使得其均值与模相同
 - 但是在非线性模型中，这一点并不成立
- 我们从一个简单的例子入手：双目相机模型



双目相机的视差与距离成反比: $y = \frac{fb}{x} + n$

x: 路标点深度; y: 视差; f: 焦距; b: 基线; n: 噪声



引言

- 考虑双目模型中，已知视差时，路标点距离的分布 $p(x|y)$
- 那么，使用贝叶斯推断：

$$p(x|y) = \frac{p(y|x)p(x)}{\int_{-\infty}^{\infty} p(y|x)p(x)dx} \quad \text{需要知道 } p(x) \text{ 和 } p(y|x)$$

- $p(y|x)$ 是容易计算的，因为噪声服从高斯分布：

$$p(y|x) = \mathcal{N}\left(\frac{fb}{x}, R\right) = \frac{1}{\sqrt{2\pi R}} \exp\left(-\frac{1}{2R} \left(y - \frac{fb}{x}\right)^2\right)$$

- 同时也假设先验服从高斯分布： $p(x) = \mathcal{N}(\check{x}, \check{P}) = \frac{1}{\sqrt{2\pi\check{P}}} \exp\left(-\frac{1}{2\check{P}} (x - \check{x})^2\right)$
- 那么整件事情可以用蒙特卡洛仿真出来



引言


- 确定仿真的操作顺序： 给定先验 \rightarrow 采样 $x_{\text{true}} \rightarrow$ 采样 $y_{\text{meas}} \rightarrow$ 计算后验 □ 注意仿真和实际是不同的

- 代入一些参数：

$$\tilde{x} = 20[\text{m}], \quad \tilde{P} = 9[\text{m}^2]$$

$$f = 400[\text{pixel}], \quad b = 0.1[\text{m}], \quad R = 0.09[\text{pixel}^2]$$

- 就可以得到后验估计的分布：



这个实验当中几个结论：

- 后验比先验更加确定了（分布更“瘦”）
- 后验不是对称的，左侧低右侧高
- 后验是单峰的，容易用高斯分布近似之


它体现了状态估计的思想：

- 将测量结果考虑进来后，得到更加确定的后验状态分布
- 但是其实这个例子取值取得并不巧，你能看出来吗？



引言

- MAP解就是后验分布的最高值，同时也是 $-\ln(p(x|y))$ 的最低值
- 由于后验分布不是对称的，因此往往不等于均值



MAP目标函数:

$$\hat{x}_{\text{map}} = \arg \max_x p(x|y)$$

对应的负对数形式:

$$\hat{x}_{\text{map}} = \arg \min_x (-\ln(p(y|x)) - \ln(p(x)))$$

搁双目模型里:

$$J(x) = \frac{1}{2R} \left(y - \frac{fb}{x} \right)^2 + \frac{1}{2\tilde{P}} (\tilde{x} - x)^2$$

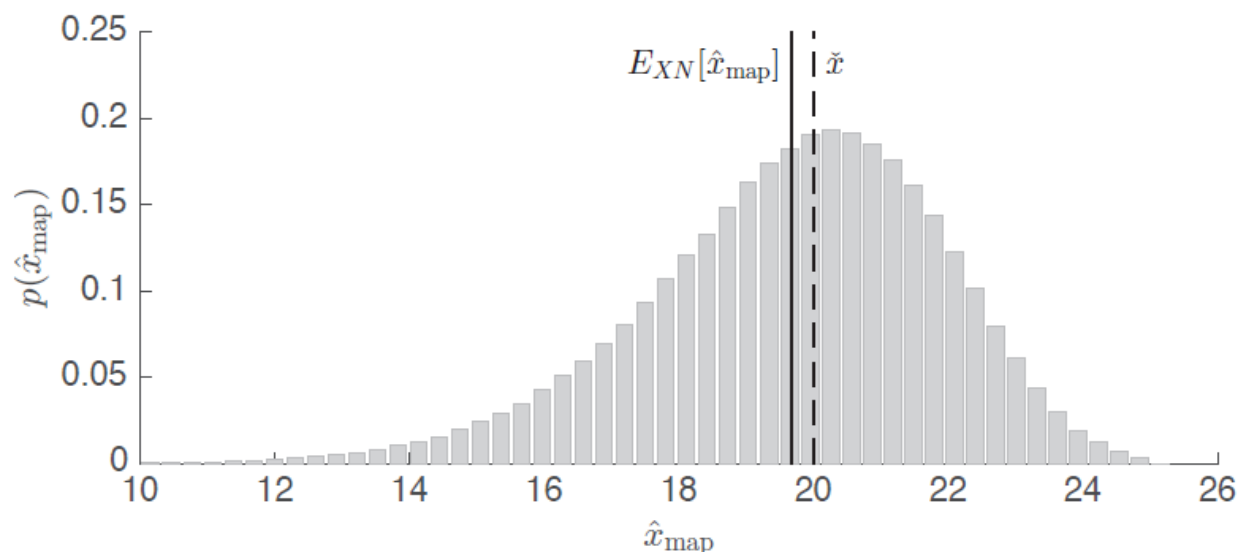


引言

• MAP的估计是否准确？

- 我们可以计算后验分布与真值之差的期望： $e_{\text{mean}}(\hat{x}) = E_{XN}[\hat{x} - x_{\text{true}}]$
- 显然MAP是有偏的，因为MAP值和先验均值并不在一条线上
- 我们也可以用平均平方误差来衡量精度： $e_{\text{sq}}(\hat{x}) = E_{XN}[(\hat{x} - x_{\text{true}})^2]$

- 下标XN表示对X和N取样
- 上面的是均值与均值之差
- 下面的是个例之间的均值



这个例子中，结论是：

$$e_{\text{mean}} \approx -33.0\text{cm}$$

$$e_{\text{sq}} \approx 4.41\text{m}^2$$

- 第1项指标明显小很多，因为只显示了均值与均值之差异，单次估计的正反向可以消除
- 相比来说，激光的深度误差约在2cm左右



第3讲 非线性高斯系统的状态估计问题

- 引言
- 离散时间的递归估计
- 离散时间的批量估计
- 连续时间的批量估计



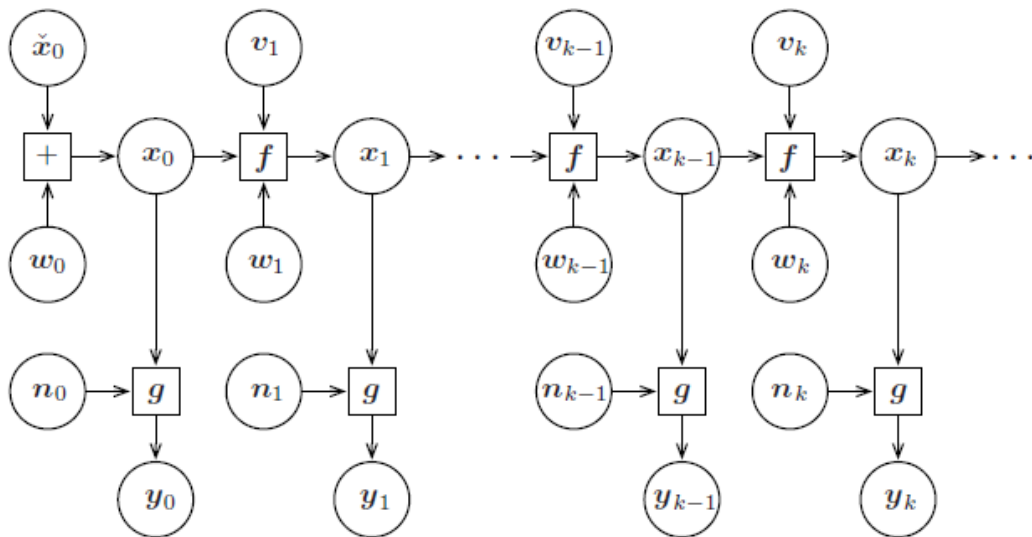
离散时间的递归估计

- 非线性系统下的运动方程与观测方程：

$$\text{运动方程: } x_k = f(x_{k-1}, v_k, w_k), \quad k = 1, \dots, K$$

$$\text{观测方程: } y_k = g(x_k, n_k), \quad k = 0, \dots, K$$

- 对应的图模型：



图模型的马尔可夫性：

- 给定现在时刻的状态时，未来时刻状态与过去时刻是条件独立的
- 具体地说，给定 $x(k-1)$ 时，就可以递推地计算 $x(k)$
- 在NLNG系统中是否有和LG系统一样的性质呢？



离散时间的递归估计

- 我们仍然从贝叶斯推断开始讨论，由于是递归的，也称为贝叶斯滤波
- 当前时刻的状态分布： $p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k})$ ，同时假设各时刻的输入、观测都是独立的
- 用贝叶斯公式分离最新的观测 $y(k)$ ：

$$p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k}) = \eta p(y_k | x_k) p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k-1})$$

- 第1项容易处理，第2项需要引入 $k-1$ 时刻的状态：

$$\begin{aligned} p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k-1}) &= \int p(x_k, x_{k-1} | \tilde{x}_0, v_{1:k}, y_{0:k-1}) dx_{k-1} \\ &= \int p(x_k | x_{k-1}, \tilde{x}_0, v_{1:k}, y_{0:k-1}) p(x_{k-1} | \tilde{x}_0, v_{1:k}, y_{0:k-1}) dx_{k-1} \end{aligned}$$

□ 又出现了联合=条件*边缘的形式

□ 请读者对此保持敏感

- 而由于马尔可夫性，不必再引入 $k-1$ 时刻之前的内容：

$$p(x_k | x_{k-1}, \tilde{x}_0, v_{1:k}, y_{0:k-1}) = p(x_k | x_{k-1}, v_k)$$

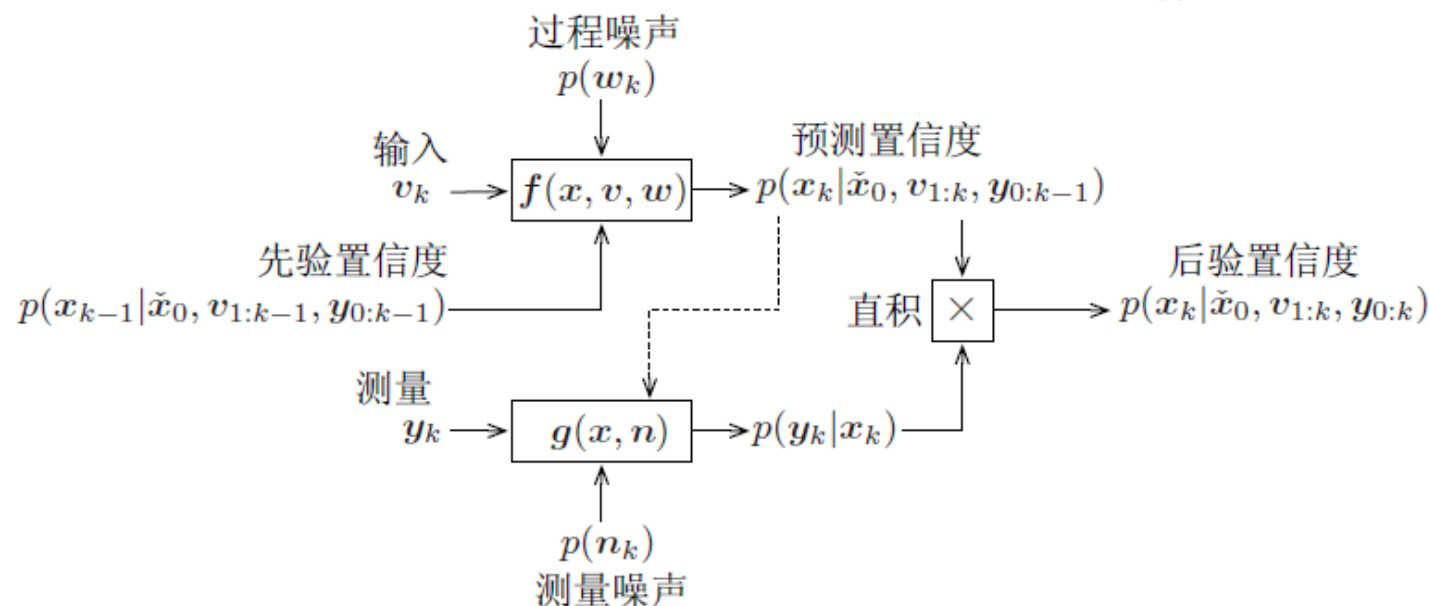
$$p(x_{k-1} | \tilde{x}_0, v_{1:k}, y_{0:k-1}) = p(x_{k-1} | \tilde{x}_0, v_{1:k-1}, y_{0:k-1})$$



离散时间的递归估计

- 综上，可整理出贝叶斯滤波器：

$$\begin{aligned}
 & \underbrace{p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k})}_{\text{后验置信度}} \\
 &= \eta \underbrace{p(y_k | x_k)}_{\text{利用 } g(\cdot) \text{ 进行更新}} \int \underbrace{p(x_k | x_{k-1}, v_k)}_{\text{利用 } f(\cdot) \text{ 进行预测}} \underbrace{p(x_{k-1} | \tilde{x}_0, v_{1:k-1}, y_{0:k-1})}_{\text{先验置信度}} dx_{k-1}
 \end{aligned}$$



好看吗？确实好看

- 怎么实现呢？
- 某种参数化形式来存储分布？（粒子、高斯）
- 怎么计算分布的非线性变换？（闭式、蒙特卡洛）
- 如果允许一定形式的近似，就会有一些经典结论
- 不要忘记这个过程中使用了马尔可夫性



离散时间的递归估计

- 扩展卡尔曼滤波 (Extended Kalman Filter)

- 在贝叶斯滤波基础之上, 假设状态分布为高斯的: $p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k}) = \mathcal{N}(\hat{x}_k, \hat{P}_k)$

- 同时, 噪声也是高斯的:

$$w_k \sim \mathcal{N}(0, Q_k)$$

$$n_k \sim \mathcal{N}(0, R_k)$$

- 我们希望推导这种系统的闭式解。在第1讲中, 我们谈论过线性化方法, 现在对运动方程和观测方程进行线性化:

$$f(x_{k-1}, v_k, w_k) \approx \tilde{x}_k + F_{k-1}(x_{k-1} - \hat{x}_{k-1}) + w'_k$$

□ 注意噪声也要线性化

$$g(x_k, n_k) \approx \tilde{y}_k + G_k(x_k - \tilde{x}_k) + n'_k$$

□ 线性化之后带一撇

其中:

$$\begin{aligned} \tilde{x}_k &= f(\hat{x}_{k-1}, v_k, 0), & F_{k-1} &= \left. \frac{\partial f(x_{k-1}, v_k, w_k)}{\partial x_{k-1}} \right|_{\hat{x}_{k-1}, v_k, 0} \\ \tilde{y}_k &= g(\tilde{x}_k, 0), & G_k &= \left. \frac{\partial g(x_k, n_k)}{\partial x_k} \right|_{\tilde{x}_k, 0} \\ w'_k &= \left. \frac{\partial f(x_{k-1}, v_k, w_k)}{\partial w_k} \right|_{\hat{x}_{k-1}, v_k, 0} w_k & n'_k &= \left. \frac{\partial g(x_k, n_k)}{\partial n_k} \right|_{\tilde{x}_k, 0} n_k \end{aligned}$$



离散时间的递归估计

- 线性化之后，模型就是线性的，处理方式和之前一样
- 运动方程的结果： $p(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{v}_k) \approx \mathcal{N}(\check{\mathbf{x}}_k + \mathbf{F}_{k-1}(\mathbf{x}_{k-1} - \hat{\mathbf{x}}_{k-1}), \mathbf{Q}'_k)$
- 观测方程的结果： $p(\mathbf{y}_k | \mathbf{x}_k) \approx \mathcal{N}(\check{\mathbf{y}}_k + \mathbf{G}_k(\mathbf{x}_k - \check{\mathbf{x}}_k), \mathbf{R}'_k)$
- 把这些代入贝叶斯滤波：

$$\underbrace{p(\mathbf{x}_k | \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k})}_{\mathcal{N}(\hat{\mathbf{x}}_k, \hat{\mathbf{P}}_k)} = \eta \underbrace{p(\mathbf{y}_k | \mathbf{x}_k)}_{\mathcal{N}(\check{\mathbf{y}}_k + \mathbf{G}_k(\mathbf{x}_k - \check{\mathbf{x}}_k), \mathbf{R}'_k)} \\ \times \int \underbrace{p(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{v}_k)}_{\mathcal{N}(\check{\mathbf{x}}_k + \mathbf{F}_{k-1}(\mathbf{x}_{k-1} - \hat{\mathbf{x}}_{k-1}), \mathbf{Q}'_k)} \underbrace{p(\mathbf{x}_{k-1} | \check{\mathbf{x}}_0, \mathbf{v}_{1:k-1}, \mathbf{y}_{0:k-1})}_{\mathcal{N}(\hat{\mathbf{x}}_{k-1}, \hat{\mathbf{P}}_{k-1})} d\mathbf{x}_{k-1}$$

- 注意下方实际对应运动方程
- 这个式子的结论我们先前推导过



离散时间的递归估计

- 我们在第1讲中介绍过高斯分布的非线性变换:

$$\begin{aligned}
 g(x) &\approx \mu_y + G(x - \mu_x) \\
 p(y|x) &= \mathcal{N}(g(x), R) \quad G = \left. \frac{\partial g(x)}{\partial x} \right|_{x=\mu_x} \quad y \sim \mathcal{N}(\mu_y, \Sigma_{yy}) = \mathcal{N}(g(\mu_x), R + G \Sigma_{xx} G^T) \\
 \mu_y &= g(\mu_x)
 \end{aligned}$$

- 所以第2项应为:

$$\begin{aligned}
 &\underbrace{p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k})}_{\mathcal{N}(\hat{x}_k, \hat{P}_k)} = \eta \underbrace{p(y_k | x_k)}_{\mathcal{N}(\tilde{y}_k + G_k(x_k - \tilde{x}_k), R'_k)} \\
 &\times \underbrace{\int p(x_k | x_{k-1}, v_k) p(x_{k-1} | \tilde{x}_0, v_{1:k-1}, y_{0:k-1}) dx_{k-1}}_{\mathcal{N}(\tilde{x}_k, F_{k-1} \hat{P}_{k-1} F_{k-1}^T + Q'_k)}
 \end{aligned}$$

- 于是只须计算高斯分布的归一化积即可



离散时间的递归估计

- 经过一些乏味的代数运算 (tedious algebra) 可以推出EKF经典表达式 (原话)
- 我们给出这里推导的思路, 把具体步骤**留作习题**
 1. 写出归一化积指数部分, 它们应该是 $x(k)$ 的二次型;
 2. 比较 $x(k)$ 二次项系数与一次项系数, 得到协方差和均值的表达式; 此时你得到信息形式的EKF;
 3. 定义卡尔曼增益, 推导见第2讲37页, 使用SMW得到它两种不同形式;
 4. 利用卡尔曼增益, 改写第2步中的信息形式, 整理成经典形式的EKF
- 实际上大部分推导过程在上讲里已经介绍过了, 只需依样画葫芦即可

$$\underbrace{p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k})}_{\mathcal{N}(\hat{x}_k, \hat{P}_k)} = \eta \underbrace{p(y_k | x_k)}_{\mathcal{N}(\tilde{y}_k + G_k(x_k - \tilde{x}_k), R'_k)} \\
 \times \underbrace{\int p(x_k | x_{k-1}, v_k) p(x_{k-1} | \tilde{x}_0, v_{1:k-1}, y_{0:k-1}) dx_{k-1}}_{\mathcal{N}(\tilde{x}_k, F_{k-1} \hat{P}_{k-1} F_{k-1}^T + Q'_k)}$$



离散时间的递归估计

- EKF的经典形式：
 - 绝大部分与KF相同
 - 预测过程使用非线性模型得到先验均值；
 - 更新过程使用先验均值和非线性模型得到观测的预测值
- EKF的问题
 - 并不保证在一般非线性系统中适用或收敛；
 - 即使收敛时，也常常是有偏的或不一致的；
 - 线性化点是估计状态的均值，但离真值有可能较远；

预测：

$$\check{P}_k = F_{k-1} \hat{P}_{k-1} F_{k-1}^T + Q'_k$$

$$\check{x}_k = f(\hat{x}_{k-1}, v_k, 0)$$

卡尔曼增益：

$$K_k = \check{P}_k G_k^T (G_k \check{P}_k G_k^T + R'_k)^{-1}$$

更新：

$$\hat{P}_k = (1 - K_k G_k) \check{P}_k$$

$$\hat{x}_k = \check{x}_k + K_k \underbrace{(y_k - g(\check{x}_k, 0))}_{\text{更新量}}$$



离散时间的递归估计

- 广义高斯滤波
- 从k-1时刻的高斯先验开始: $p(\mathbf{x}_{k-1} | \check{\mathbf{x}}_0, \mathbf{v}_{1:k-1}, \mathbf{y}_{0:k-1}) = \mathcal{N}(\hat{\mathbf{x}}_{k-1}, \hat{\mathbf{P}}_{k-1})$
- 通过运动模型, 得到k时刻的先验: $p(\mathbf{x}_k | \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1}) = \mathcal{N}(\check{\mathbf{x}}_k, \check{\mathbf{P}}_k)$
- 校正部分, 先写出联合分布, 然后使用高斯推断:

$$p(\mathbf{x}_k, \mathbf{y}_k | \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1}) = \mathcal{N}\left(\begin{bmatrix} \boldsymbol{\mu}_{x,k} \\ \boldsymbol{\mu}_{y,k} \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{xx,k} & \boldsymbol{\Sigma}_{xy,k} \\ \boldsymbol{\Sigma}_{yx,k} & \boldsymbol{\Sigma}_{yy,k} \end{bmatrix}\right)$$

- 那么条件概率为:

$$\begin{aligned} & p(\mathbf{x}_k | \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k}) \\ &= \mathcal{N}\left(\underbrace{\boldsymbol{\mu}_{x,k} + \boldsymbol{\Sigma}_{xy,k} \boldsymbol{\Sigma}_{yy,k}^{-1} (\mathbf{y}_k - \boldsymbol{\mu}_{y,k})}_{\hat{\mathbf{x}}_k}, \underbrace{\boldsymbol{\Sigma}_{xx,k} - \boldsymbol{\Sigma}_{xy,k} \boldsymbol{\Sigma}_{yy,k}^{-1} \boldsymbol{\Sigma}_{yx,k}}_{\hat{\mathbf{P}}_k}\right) \end{aligned}$$

- 注意这里并没有给出联合分布的计算方式
- 如果考虑观测的线性化, 则y部分可以写出



离散时间的递归估计

- 然后定义卡尔曼增益:

$$K_k = \Sigma_{xy,k} \Sigma_{yy,k}^{-1}$$

$$\hat{P}_k = \check{P}_k - K_k \Sigma_{xy,k}^T$$

$$\hat{x}_k = \check{x}_k + K_k (y_k - \mu_{y,k})$$

- 就可以得到类EKF的过程
 - 但是这个思路中, 如果不作线性化, 则 $\mu_{y,k}$, $\Sigma_{yy,k}$ 和 $\Sigma_{xy,k}$ 无法计算, 因为 y 是 x 的非线性变换, 并不是高斯的
 - 不过, 如果使用线性化, 则可以进一步推导



离散时间的递归估计

- 迭代卡尔曼滤波

- 首先对观测部分进行线性化:

$$g(x_k, n_k) \approx y_{\text{op},k} + G_k(x_k - x_{\text{op},k}) + n'_k$$

- 那么k时刻状态与观测的联合分布可写为:

$$\begin{aligned} p(x_k, y_k | \check{x}_0, v_{1:k}, y_{0:k-1}) &\approx \mathcal{N} \left(\begin{bmatrix} \mu_{x,k} \\ \mu_{y,k} \end{bmatrix}, \begin{bmatrix} \Sigma_{xx,k} & \Sigma_{xy,k} \\ \Sigma_{yx,k} & \Sigma_{yy,k} \end{bmatrix} \right) \\ &= \mathcal{N} \left(\begin{bmatrix} \check{x}_k \\ y_{\text{op},k} + G_k(\check{x}_k - x_{\text{op},k}) \end{bmatrix}, \begin{bmatrix} \check{P}_k & \check{P}_k G_k^T \\ G_k \check{P}_k & G_k \check{P}_k G_k^T + R'_k \end{bmatrix} \right) \end{aligned}$$

- 利用高斯推断, 写出条件概率密度: $p(x_k | \check{x}_0, v_{1:k}, y_{0:k})$

$$= \mathcal{N} \left(\underbrace{\mu_{x,k} + \Sigma_{xy,k} \Sigma_{yy,k}^{-1} (y_k - \mu_{y,k})}_{\hat{x}_k}, \underbrace{\Sigma_{xx,k} - \Sigma_{xy,k} \Sigma_{yy,k}^{-1} \Sigma_{yx,k}}_{\hat{P}_k} \right)$$

其中

$$y_{\text{op},k} = g(x_{\text{op},k}, 0), \quad G_k = \left. \frac{\partial g(x_k, n_k)}{\partial x_k} \right|_{x_{\text{op},k}, 0}$$

$$n'_k = \left. \frac{\partial g(x_k, n_k)}{\partial n_k} \right|_{x_{\text{op},k}, 0} n_k$$



离散时间的递归估计

- 定义卡尔曼增益，然后写出均值与协方差的更新式：

$$K_k = \Sigma_{xy,k} \Sigma_{yy,k}^{-1}$$

$$\hat{P}_k = \check{P}_k - K_k \Sigma_{xy,k}^T$$

$$\hat{x}_k = \check{x}_k + K_k (y_k - \mu_{y,k})$$

- 代入非线性模型：

$$K_k = \check{P}_k G_k^T (G_k \check{P}_k G_k^T + R'_k)^{-1}$$

$$\hat{P}_k = (1 - K_k G_k) \check{P}_k$$

$$\hat{x}_k = \check{x}_k + K_k (y_k - y_{\text{op},k} - G_k (\check{x}_k - x_{\text{op},k}))$$

- 该结论和EKF是一致的

- 但是这里显式定义了线性化的工作点 $x_{\text{op},k}$ ，而在EKF中取

$$x_{\text{op},k} = \check{x}_k$$

- 事实上我们可以不断迭代，然后把上一次迭代结果作为下一次的线性化点：


$$x_{\text{op},k} \leftarrow \hat{x}_k$$

- 就可以得到更好的结果。这种滤波器称为迭代的EKF (IEKF)



离散时间的递归估计

- EKF、IEKF、MAP之间的关系
 - IEKF对应后验概率的极大值，事实上是一个估计；
 - 而EKF只处理一次线性化，相当于只迭代一步，很难说这次迭代能走到什么程度；
 - 在本课开头的双目例子中，可以得到如下仿真结果：




实验结果：

- IEKF的均值是一个MAP解
- 全贝叶斯估计 $p(x|y)$ 、MAP解与真实 x 之间是有偏的
- IEKF和MAP解优于EKF



离散时间的递归估计

- 处理非线性函数的其他方法
 - 前面主要介绍了在工作点处线性化方法处理非线性函数
 - 实际中还其他的手段，例如蒙特卡罗法、sigma point 变换法等等
- 蒙特卡罗方法 (Monte Carlo Method)
 - 在非线变换中，对输入分布大量采样，计算非线性变换后的值，再用变换后的值构建输出分布
 - 大数定律保证了当样本数量接近无穷大时，不管什么分布和什么变换，都能得到正确的值
 - 计算量随着维度指数增长，不过采样数量可以人为控制；采样数量很大时，是最准确的方法
 - 我们在双目例子中就使用了蒙特卡罗法来衡量不同估计器的结果






离散时间的递归估计

• 线性化方法

- 线性化方法就是我们前面介绍EKF时的方法
- 具体来说，就是以x均值点为工作点，进行线性化后得到y的分布



这个实际上是非常不准确的，因为：


1. 高斯分布的非线性变换本身不再是高斯分布，我们不知道它是什么分布，只保留了那个分布的一、二阶矩
2. 非线性变换的线性化本身存在误差
3. 线性化点理论上是x均值，但实际当中是x均值的估计值，它也可能是个错误的值
4. y均值=g(x均值) 是成问题的

- 如果函数是近似线性的，那么线性化效果不错
- 但如果函数是高度非线性的，那么很难说单次线性化会怎么样



离散时间的递归估计

- Sigma Point变换（SP变换，或无迹变换）
 - 是线性化方法和蒙特卡尔方法的折中
 - 核心思想：选定输入分布的几个点（Sigma Point），计算这几个点的非线性变换，用它的结果构建输出分布
 - 最简单的一维SP如下所示：





离散时间的递归估计

- 高维（L维）高斯分布的sigma point（共 $2L+1$ 个）：

$$LL^T = \Sigma_{xx}, \text{ (Cholesky 分解, } L \text{ 为下三角矩阵)}$$

$$x_0 = \mu_x$$

$$x_i = \mu_x + \sqrt{L + \kappa} \text{col}_i L$$

$$x_{i+L} = \mu_x - \sqrt{L + \kappa} \text{col}_i L \quad i = 1, \dots, L$$

□ 其中 κ 是一个自定义常数,

□ col表示取L的第i列

- 这些样本点满足：

$$\mu_x = \sum_{i=0}^{2L} \alpha_i x_i$$

$$\Sigma_{xx} = \sum_{i=0}^{2L} \alpha_i (x_i - \mu_x)(x_i - \mu_x)^T$$

其中：

$$\alpha_i = \begin{cases} \frac{\kappa}{L+\kappa} & i = 0 \\ \frac{1}{2} \frac{1}{L+\kappa} & \text{其他} \end{cases}$$

□ 习题：请验证此式



离散时间的递归估计

- 对Sigma Point进行非线性变换, 得到: $y_i = g(x_i), \quad i = 0, \dots, 2L$
- 用y的结果构建输出高斯分布:

$$\mu_y = \sum_{i=0}^{2L} \alpha_i y_i \quad \Sigma_{yy} = \sum_{i=0}^{2L} \alpha_i (y_i - \mu_y)(y_i - \mu_y)^T$$

- Sigma Point的好处:
 - 不用计算线性化雅可比矩阵;
 - 仅使用了标准矩阵加法乘法和Cholesky分解;
 - 对非线性函数的要求很少 (不要求光滑和可微)



离散时间的递归估计

- 下面通过例子来比较各方法的优劣
- 输入： $\mathcal{N}(\mu_x, \sigma_x^2)$ ，非线性变换： $f(x) = x^2$
- 蒙特卡罗方法（闭式的）：

• 采样点： $x_i = \mu_x + \delta x_i, \quad \delta x_i \leftarrow \mathcal{N}(0, \sigma_x^2)$

• 非线性变换： $y_i = f(x_i) = f(\mu_x + \delta x_i) = (\mu_x + \delta x_i)^2 = \mu_x^2 + 2\mu_x \delta x_i + \delta x_i^2$

• 它的均值和方差： $\mu_y = E[y_i] = \mu_x^2 + 2\mu_x \underbrace{E[\delta x_i]}_0 + \underbrace{E[\delta x_i^2]}_{\sigma_x^2} = \mu_x^2 + \sigma_x^2$

$$\sigma_y^2 = E[(y_i - \mu_y)^2]$$

$$= E[(2\mu_x \delta x_i + \delta x_i^2 - \sigma_x^2)^2]$$

$$= \underbrace{E[\delta x_i^4]}_{3\sigma_x^4} + 4\mu_x \underbrace{E[\delta x_i^3]}_0 + (4\mu_x^2 - 2\sigma_x^2) \underbrace{E[\delta x_i^2]}_{\sigma_x^2} - 4\mu_x \sigma_x^2 \underbrace{E[\delta x_i]}_0 + \sigma_x^4$$

$$= 4\mu_x^2 \sigma_x^2 + 2\sigma_x^4$$

□ 众所周知，输出分布的实际学名是卡方分布

□ 如果近似为高斯分布，那么仅取其一二阶矩即可（图像上来看其实并不像）

□ 高斯分布的三、四阶矩可以当作结论来记，如果想自己推的话，参考教材第2章Isserlis定理（本课程略去）



离散时间的递归估计

- 线性化方法: $y_i = f(\mu_x + \delta x_i) \approx \underbrace{f(\mu_x)}_{\mu_x^2} + \underbrace{\frac{\partial f}{\partial x} \Big|_{\mu_x}}_{2\mu_x} \delta x_i = \mu_x^2 + 2\mu_x \delta x_i$

- 线性化后的期望与方差:

$$\mu_y = E[y_i] = \mu_x^2 + 2\mu_x \underbrace{E[\delta x_i]}_0 = \mu_x^2 \qquad \sigma_y^2 = E[(y_i - \mu_y)^2] = E[(2\mu_x \delta x_i)^2] = 4\mu_x^2 \sigma_x^2$$

- 对比上一页蒙特卡罗法, 可见均值是有偏的, 而且方差过小了 (Overconfident)



离散时间的递归估计

- Sigma point变换:

- 选取3个sigma point: $x_0 = \mu_x$, $x_1 = \mu_x + \sqrt{1 + \kappa}\sigma_x$, $x_2 = \mu_x - \sqrt{1 + \kappa}\sigma_x$

- 代入非线性变换: $y_0 = f(x_0) = \mu_x^2$

$$y_1 = f(x_1) = (\mu_x + \sqrt{1 + \kappa}\sigma_x)^2 = \mu_x^2 + 2\mu_x\sqrt{1 + \kappa}\sigma_x + (1 + \kappa)\sigma_x^2$$

$$y_2 = f(x_2) = (\mu_x - \sqrt{1 + \kappa}\sigma_x)^2 = \mu_x^2 - 2\mu_x\sqrt{1 + \kappa}\sigma_x + (1 + \kappa)\sigma_x^2$$

- 输出分布:

$$\begin{aligned}\mu_y &= \frac{1}{1 + \kappa} \left(\kappa y_0 + \frac{1}{2} \sum_{i=1}^2 y_i \right) \\ &= \frac{1}{1 + \kappa} \left(\kappa \mu_x^2 + \frac{1}{2} (\mu_x^2 + 2\mu_x\sqrt{1 + \kappa}\sigma_x + (1 + \kappa)\sigma_x^2 + \mu_x^2 \right. \\ &\quad \left. - 2\mu_x\sqrt{1 + \kappa}\sigma_x + (1 + \kappa)\sigma_x^2) \right) \\ &= \frac{1}{1 + \kappa} (\kappa \mu_x^2 + \mu_x^2 + (1 + \kappa)\sigma_x^2) \\ &= \mu_x^2 + \sigma_x^2\end{aligned}$$


$$\begin{aligned}\sigma_y^2 &= \frac{1}{1 + \kappa} \left(\kappa (y_0 - \mu_y)^2 + \frac{1}{2} \sum_{i=1}^2 (y_i - \mu_y)^2 \right) \\ &= \frac{1}{1 + \kappa} \left(\kappa \sigma_x^4 + \frac{1}{2} \left((2\mu_x\sqrt{1 + \kappa}\sigma_x + \kappa\sigma_x^2)^2 \right. \right. \\ &\quad \left. \left. + (-2\mu_x\sqrt{1 + \kappa}\sigma_x + \kappa\sigma_x^2)^2 \right) \right) \\ &= \frac{1}{1 + \kappa} (\kappa \sigma_x^4 + 4(1 + \kappa)\mu_x^2\sigma_x^2 + \kappa^2\sigma_x^4) \\ &= 4\mu_x^2\sigma_x^2 + \kappa\sigma_x^4\end{aligned}$$

□ 取 $\kappa=2$ 时, 得到真实的均值和方差



离散时间的递归估计

- 三种方法的结果对比:



- 精确变换并不是高斯的
- 蒙特卡罗（闭式）可看成最优近似
- Sigma-point在 $\kappa=2$ 时与蒙特卡罗法相同
- 线性化的均值和方差都有少许差异，均值有偏，方差较小（更瘦）



离散时间的递归估计

- 粒子滤波
 - 粒子滤波是唯一一种可以处理NLNG系统的实用技术
 - 而且特别简单
- 粒子滤波算法流程

1. 采样：从先验与运动噪声中采样M个样本：

$$\begin{bmatrix} \hat{x}_{k-1,m} \\ w_{k,m} \end{bmatrix} \leftarrow p(x_{k-1} | \tilde{x}_0, v_{1:k-1}, y_{1:k-1}) p(w_k)$$

2. 使用运动方程得到预测分布：

$$\tilde{x}_{k,m} = f(\hat{x}_{k-1,m}, v_k, w_{k,m})$$

3. 使用观测方程进行校正

(a) 为每个粒子计算权重：

$$w_{k,m} = \frac{p(\tilde{x}_{k,m} | \tilde{x}_0, v_{1:k}, y_{1:k})}{p(\tilde{x}_{k,m} | \tilde{x}_0, v_{1:k}, y_{1:k-1})} = \eta p(y_k | \tilde{x}_{k,m}) \quad \tilde{y}_{k,m} = g(\tilde{x}_{k,m}, 0)$$

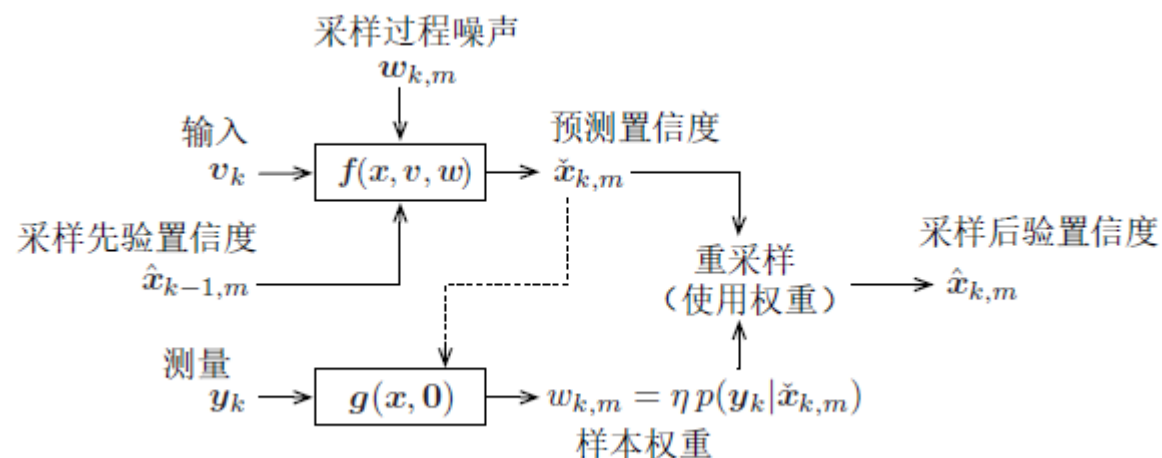
(b) 对粒子进行重要性重采样 (Sample importance resampling) , 具体方法见下一页

$$\hat{x}_{k,m} \xleftarrow{\text{重要性重采样}} \{\tilde{x}_{k,m}, w_{k,m}\}$$



离散时间的递归估计

- 粒子滤波的算法流程图示
- 注解：
 - 需要粒子数量和问题维度有关（三自由度定位使用几百个粒子即可），随维度指数增长
 - 粒子数量也可动态设置
 - 重采样可以每隔一段时间做一次



Madow的重采样算法[36]（轮盘赌）：

- 设粒子具有归一化的权重： $w_m \in \mathbb{R} > 0$ ，那么按照权重建立 $[0,1]$ 上的小区间：
$$\beta_m = \frac{\sum_{n=1}^m w_n}{\sum_{\ell=1}^M w_\ell}$$
- 在 $[0,1)$ 上取均匀分布随机数，把区间内的样本作为重采样样本；

[36] Madow W G. On the Theory of Systematic Sampling, II. The Annals of Mathematical Statistics, 1949, 30:333–354.



离散时间的递归估计

- SPKF(UKF) 无迹卡尔曼滤波
 - 将sigma point变换应用到卡尔曼的运动和观测模型中
 - 预测部分：先把状态和运动噪声放在一起写成联合形式，设其维度为L：

$$\mu_z = \begin{bmatrix} \hat{x}_{k-1} \\ 0 \end{bmatrix}, \quad \Sigma_{zz} = \begin{bmatrix} \hat{P}_{k-1} & 0 \\ 0 & Q_k \end{bmatrix}$$

- 取Sigma point，然后代入运动模型：

其中： $z_i = \begin{bmatrix} \hat{x}_{k-1,i} \\ w_{k,i} \end{bmatrix}$

$LL^T = \Sigma_{zz}$, (Cholesky 分解, L 为下三角矩阵)

$$z_0 = \mu_z$$

$$z_i = \mu_z + \sqrt{L + \kappa \text{col}_i} L$$

$$z_{i+L} = \mu_z - \sqrt{L + \kappa \text{col}_i} L \quad i = 1, \dots, L$$

代入运动模型后： $\tilde{x}_{k,i} = f(\hat{x}_{k-1,i}, v_k, w_{k,i}), \quad i = 0, \dots, 2L$

得到预测的先验： $\tilde{x}_k = \sum_{i=0}^{2L} \alpha_i \tilde{x}_{k,i}$

$$\tilde{P}_k = \sum_{i=0}^{2L} \alpha_i (\tilde{x}_{k,i} - \tilde{x}_k)(\tilde{x}_{k,i} - \tilde{x}_k)^T$$



离散时间的递归估计

• SPKF校正步骤:

1. 把预测和观测噪声写在一起: $\mu_z = \begin{bmatrix} \tilde{x}_k \\ 0 \end{bmatrix}$, $\Sigma_{zz} = \begin{bmatrix} \bar{P}_k & 0 \\ 0 & R_k \end{bmatrix}$

2. Sigma Point变换:

$LL^T = \Sigma_{zz}$, (Cholesky 分解, L 为下三角矩阵)

$$\begin{aligned} z_0 &= \mu_z \\ z_i &= \mu_z + \sqrt{L + \kappa} \text{col}_i L \\ z_{i+L} &= \mu_z - \sqrt{L + \kappa} \text{col}_i L \end{aligned} \quad i = 1, \dots, L \quad z_i = \begin{bmatrix} \tilde{x}_{k,i} \\ n_{k,i} \end{bmatrix}$$

3. 构建后验分布:

$$\begin{aligned} \mu_{y,k} &= \sum_{i=0}^{2L} \alpha_i \tilde{y}_{k,i} \\ \Sigma_{yy,k} &= \sum_{i=0}^{2L} \alpha_i (\tilde{y}_{k,i} - \mu_{y,k})(\tilde{y}_{k,i} - \mu_{y,k})^T \\ \Sigma_{xy,k} &= \sum_{i=0}^{2L} \alpha_i (\tilde{x}_{k,i} - \tilde{x}_k)(\tilde{y}_{k,i} - \mu_{y,k})^T \end{aligned}$$

代入观测方程:

$$\tilde{y}_{k,i} = g(\tilde{x}_{k,i}, n_{k,i}), \quad i = 0, \dots, 2L$$


SPKF的优势:

- ❑ 完全不要求求导
- ❑ 甚至不需要运动和观测方程的解析形式, 视为黑盒模型
- ❑ 如同IEKF之于EKF一样, SPKF也可以有迭代版本ISP KF, 本课程略去



离散时间的递归估计

- SPKF与MAP
 - 我们在之前的双目视差问题里验证SPKF的解与其他解的问题
 - SPKF中取 $\kappa=2$



结论:

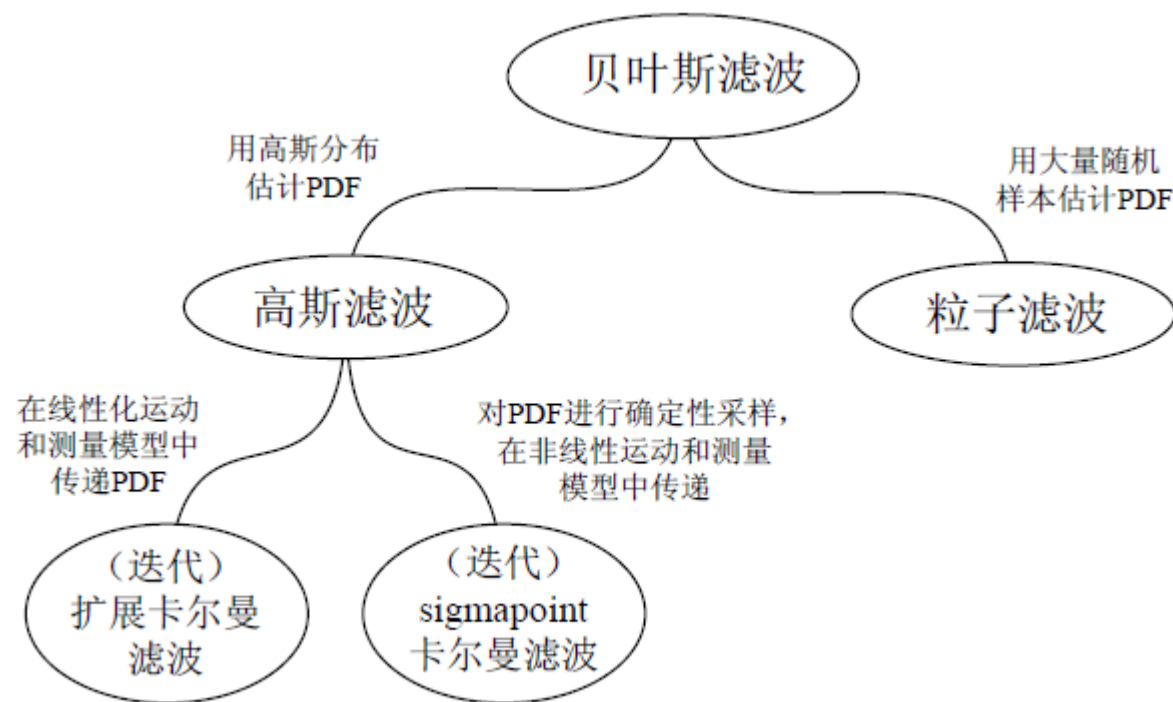
- 单次SPKF和EKF差不多, 与MAP无明显关系
- 迭代的ISPKF和真实均值更接近;

本实验中可以合理地认为ISPKF收敛于真实后验均值; 而MAP解收敛于模



离散时间的递归估计

- 本小节几种滤波器之间的关系





第3讲 非线性高斯系统的状态估计问题

- 引言
- 离散时间的递归估计
- 离散时间的批量估计
- 连续时间的批量估计



离散时间的批量估计

- 我们已经介绍了许多递归形式的滤波器，但是它们都蕴含了马尔可夫假设
- 现在我们来考察批量形式下的情况
- 从上一讲内容中，我们已经知道批量解可以等价于最小二乘问题
- 定义优化变量、优化目标函数为：

$$\mathbf{x} = \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_K \end{bmatrix}$$

优化变量

$$e_{v,k}(\mathbf{x}) = \begin{cases} \tilde{x}_0 - x_0 & k = 0 \\ f(x_{k-1}, v_k, 0) - x_k & k = 1, \dots, K \end{cases}$$

运动与观测的误差

$$e_{y,k}(\mathbf{x}) = y_k - g(x_k, 0), \quad k = 0, \dots, K$$

$$J_{v,k}(\mathbf{x}) = \frac{1}{2} e_{v,k}(\mathbf{x})^\top W_{v,k}^{-1} e_{v,k}(\mathbf{x})$$

$$J_{y,k}(\mathbf{x}) = \frac{1}{2} e_{y,k}(\mathbf{x})^\top W_{y,k}^{-1} e_{y,k}(\mathbf{x})$$

误差的马氏范数

$$J(\mathbf{x}) = \sum_{k=0}^K (J_{v,k}(\mathbf{x}) + J_{y,k}(\mathbf{x}))$$

整体优化目标



离散时间的批量估计

- 整理其矩阵形式：

$$e(x) = \begin{bmatrix} e_v(x) \\ e_y(x) \end{bmatrix}, \quad e_v(x) = \begin{bmatrix} e_{v,0}(x) \\ \vdots \\ e_{v,K}(x) \end{bmatrix}, \quad e_y(x) = \begin{bmatrix} e_{y,0}(x) \\ \vdots \\ e_{y,K}(x) \end{bmatrix}$$

$$W = \text{diag}(W_v, W_y)$$

$$W_v = \text{diag}(W_{v,0}, \dots, W_{v,K}), \quad W_y = \text{diag}(W_{y,0}, \dots, W_{y,K})$$

- 那么目标函数简单写为： $J(x) = \frac{1}{2} e(x)^T W^{-1} e(x)$
- 这是一个无约束最小二乘问题，可以通过通用的牛顿法、高斯牛顿法来求解



离散时间的批量估计

- 牛顿法
 - 不断迭代并线性化，向着最优解前进；线性化：

$$J(x_{\text{op}} + \delta x) \approx J(x_{\text{op}}) + \underbrace{\left(\frac{\partial J(x)}{\partial x} \Big|_{x_{\text{op}}} \right)}_{\text{雅可比}} \delta x + \frac{1}{2} \delta x^T \underbrace{\left(\frac{\partial^2 J(x)}{\partial x \partial x^T} \Big|_{x_{\text{op}}} \right)}_{\text{海塞}} \delta x$$

- 令线性化函数对delta x导数为零，来求得最优delta x：

$$\begin{aligned} \frac{\partial J(x_{\text{op}} + \delta x)}{\partial \delta x} &= \left(\frac{\partial J(x)}{\partial x} \Big|_{x_{\text{op}}} \right) + \delta x^{*\top} \left(\frac{\partial^2 J(x)}{\partial x \partial x^T} \Big|_{x_{\text{op}}} \right) = 0 \\ \Rightarrow \left(\frac{\partial^2 J(x)}{\partial x \partial x^T} \Big|_{x_{\text{op}}} \right) \delta x^* &= - \left(\frac{\partial J(x)}{\partial x} \Big|_{x_{\text{op}}} \right)^T \end{aligned}$$

- 然后不断迭代： $x_{\text{op}} \leftarrow x_{\text{op}} + \delta x^*$



离散时间的批量估计

- Gauss-Newton法与Levenberg-Marquardt方法
 - 基于牛顿法的改进，更为实用
 - 由于在VSLAM课程和VIO课程里均已详细介绍过，且有编程实现，此处省略；
 - 不懂的同学可以参考这两个课程的课件或者状态估计教材



离散时间的批量估计

- 回到批量估计的问题定义处：

- 批量问题的误差定义与线性化：

$$e_{v,k}(x_{\text{op}} + \delta x) \approx \begin{cases} e_{v,0}(x_{\text{op}}) - \delta x_0, & k = 0 \\ e_{v,k}(x_{\text{op}}) + F_{k-1}\delta x_{k-1} - \delta x_k, & k = 1, \dots, K \end{cases}$$

$$e_{y,k}(x_{\text{op}} + \delta x) \approx e_{y,k}(x_{\text{op}}) - G_k \delta x_k, \quad k = 0, \dots, K$$

- 定义噪声为： $W_{v,k} = Q'_k$, $W_{y,k} = R'_k$

- 那么整个问题可写成矩阵形式：

$$\delta x = \begin{bmatrix} \delta x_0 \\ \delta x_1 \\ \delta x_2 \\ \vdots \\ \delta x_K \end{bmatrix}, \quad H = \begin{bmatrix} 1 & & & & \\ -F_0 & 1 & & & \\ & -F_1 & \ddots & & \\ & & \ddots & 1 & \\ & & & -F_{K-1} & 1 \\ G_0 & & & & \\ & G_1 & & & \\ & & G_2 & & \\ & & & \ddots & \\ & & & & G_K \end{bmatrix}$$

$$e(x_{\text{op}}) = \begin{bmatrix} e_{v,0}(x_{\text{op}}) \\ e_{v,1}(x_{\text{op}}) \\ \vdots \\ e_{v,K}(x_{\text{op}}) \\ e_{y,0}(x_{\text{op}}) \\ e_{y,1}(x_{\text{op}}) \\ \vdots \\ e_{y,K}(x_{\text{op}}) \end{bmatrix}$$

雅可比矩阵：

$$F_{k-1} = \left. \frac{\partial f(x_{k-1}, v_k, w_k)}{\partial x_{k-1}} \right|_{x_{\text{op},k-1}, v_k, 0}, \quad G_k = \left. \frac{\partial g(x_k, n_k)}{\partial x_k} \right|_{x_{\text{op},k}, 0}$$

$$W = \text{diag}(\tilde{P}_0, Q'_1, \dots, Q'_K, R'_0, R'_1, \dots, R'_K)$$

Gauss-Newton的线性方程：

$$\underbrace{(H^T W^{-1} H)}_{\text{三对角块}} \delta x^* = H^T W^{-1} e(x_{\text{op}})$$

于是得到批量MAP的解法



离散时间的批量估计

- 贝叶斯推断
 - 假设整条轨迹有初值 \mathbf{x}_{op} 我们在这个点上线性化运动模型:

$$\mathbf{x}_k \approx f(\mathbf{x}_{\text{op},k-1}, \mathbf{v}_k, \mathbf{0}) + \mathbf{F}_{k-1}(\mathbf{x}_{k-1} - \mathbf{x}_{\text{op},k-1}) + \mathbf{w}'_k$$

- 通过一些数学手段, 写成提升形式:

$$\mathbf{F} = \begin{bmatrix} 1 & & & & \\ \mathbf{F}_0 & 1 & & & \\ \mathbf{F}_1\mathbf{F}_0 & \mathbf{F}_1 & 1 & & \\ \vdots & \vdots & \vdots & \ddots & \\ \mathbf{F}_{K-2}\cdots\mathbf{F}_0 & \mathbf{F}_{K-2}\cdots\mathbf{F}_1 & \mathbf{F}_{K-2}\cdots\mathbf{F}_2 & \cdots & 1 \\ \mathbf{F}_{K-1}\cdots\mathbf{F}_0 & \mathbf{F}_{K-1}\cdots\mathbf{F}_1 & \mathbf{F}_{K-1}\cdots\mathbf{F}_2 & \cdots & \mathbf{F}_{K-1} & 1 \end{bmatrix} \quad \boldsymbol{\nu} = \begin{bmatrix} \check{\mathbf{x}}_0 \\ f(\mathbf{x}_{\text{op},0}, \mathbf{v}_1, \mathbf{0}) - \mathbf{F}_0\mathbf{x}_{\text{op},0} \\ f(\mathbf{x}_{\text{op},1}, \mathbf{v}_2, \mathbf{0}) - \mathbf{F}_1\mathbf{x}_{\text{op},1} \\ \vdots \\ f(\mathbf{x}_{\text{op},K-1}, \mathbf{v}_K, \mathbf{0}) - \mathbf{F}_{K-1}\mathbf{x}_{\text{op},K-1} \end{bmatrix}$$

- 运动方程的提升形式为: $\mathbf{x} = \mathbf{F}(\boldsymbol{\nu} + \mathbf{w}')$



离散时间的批量估计

- 那么，在初值已知的情况下，先验的均值和协方差为：

$$\check{x} = E[x] = E[F(\nu + w')] = F\nu \quad \check{P} = E[(x - E[x])(x - E[x])^T] = FE \left[w' w'^T \right] F^T = FQ'F^T$$

- 于是先验记为： $x \sim \mathcal{N}(F\nu, FQ'F^T)$ 其中 $Q' = \text{diag}(\check{P}_0, Q'_1, Q'_2, \dots, Q'_K)$
- 观测模型： $y_k \approx g(x_{\text{op},k}, 0) + G_k(x_{k-1} - x_{\text{op},k-1}) + n'_k$ 提升形式： $y = y_{\text{op}} + G(x - x_{\text{op}}) + n'$
- 那么联合分布：

$$p(x, y|v) = \mathcal{N} \left(\begin{bmatrix} \check{x} \\ y_{\text{op}} + G(\check{x} - x_{\text{op}}) \end{bmatrix}, \begin{bmatrix} \check{P} & \check{P}G^T \\ G\check{P} & G\check{P}G^T + R' \end{bmatrix} \right)$$

$$y_{\text{op}} = \begin{bmatrix} g(x_{\text{op},0}, 0) \\ g(x_{\text{op},1}, 0) \\ \vdots \\ g(x_{\text{op},K}, 0) \end{bmatrix}$$

$$G = \text{diag}(G_0, G_1, G_2, \dots, G_K)$$

$$R = \text{diag}(R'_0, R'_1, R'_2, \dots, R'_K)$$



离散时间的批量估计

- 利用高斯推断可得：

$$K = \check{P}G^T (G\check{P}G^T + R')^{-1}$$

$$\hat{P} = (1 - KG)\check{P}$$

$$\hat{x} = \check{x} + K(y - y_{\text{op}} - G(\check{x} - x_{\text{op}}))$$

- 使用SMW重新组织方程： $(\check{P}^{-1} + G^T R'^{-1} G) \delta x^* = \check{P}^{-1} (\check{x} - x_{\text{op}}) + G^T R'^{-1} (y - y_{\text{op}})$

- 代入先验部分：

$$\underbrace{(F^{-T}Q'^{-1}F^{-1} + G^T R'^{-1}G)}_{\text{三对角块}} \delta x^* \\ = F^{-T}Q'^{-1}(\nu - F^{-1}x_{\text{op}}) + G^T R'^{-1}(y - y_{\text{op}})$$

其中： $\delta x^* = \hat{x} - x_{\text{op}}$

- 定义统一的矩阵： $H = \begin{bmatrix} F^{-1} \\ G \end{bmatrix}$, $W = \text{diag}(Q', R')$, $e(x_{\text{op}}) = \begin{bmatrix} \nu - F^{-1}x_{\text{op}} \\ y - y_{\text{op}} \end{bmatrix}$

- 那么批量解： $\underbrace{(H^T W^{-1} H)}_{\text{三对角块}} \delta x^* = H^T W^{-1} e(x_{\text{op}})$

□ 贝叶斯推断和MAP基本是一样的，不过显式给出了协方差的估计




离散时间的批量估计


• 讨论

- 相比于MAP, EKF的问题主要有两个: 没有迭代过程, 依赖马尔可夫假设
- EKF基本上和单次MAP迭代一样 (实际上稍微优于单次迭代)
- 相比于各种针对EKF的改进, 实际当中马尔可夫性是一个更本质的约束
- 也有Sliding Window Filter这种介于批量和递归之间的滤波方法


高斯 - 牛顿法遍历整个轨迹, 但离线运行, 且不是恒定时间



滑动窗口滤波器一次迭代多个时间步长, 在线、恒定时间运行



IEKF 一次仅迭代一个时间步长, 但可在线、恒定时间运行





离散时间的批量估计

- 本节课省略的内容
 - 高斯-牛顿法和Leverberg-Marquardt法的推导
 - 最大似然估计 (ML)
 - 连续时间的估计问题



习题

1. 完成PPT第17页的推导
2. 验证27页下方式子
3. 课后习题1